



FACULTAD DE ESTUDIOS ESTADÍSTICOS

DESCRIPCIÓN Y EXPLORACIÓN DE DATOS

ANÁLISIS ESTADÍSTICO DESCRIPTIVO

Forbes 2000

(año 2004)

Pablo Galarón Mateo

Raúl Palomo Mazo

Adolfo Alarcón Martínez

ÍNDICE

Pag 2– Introducción.

Pag 3-Profits:

- Representación gráfica.
- Medidas de posición.
- Medidas de dispersión.
- Medidas de forma.
- Análisis de datos anómalos.
- Índice de Ginni.
- Google colab.

Pag 15- Market value:

- Introducción.
- Tabla y representaciones gráficas.
- Medidas de posición.
- Medidas de dispersión.
- Medidas de forma
- Análisis de datos anómalos
- Índice de Ginni.
- Google Colab

Pag 25-Sectores y Nacionalidades:

- Tablas.
- Comparación con datos anómalos.
- Índices de Ginni.
- Medidas de dispersión.
- Medidas de posición.
- Google colab.

Pag 35: Conclusión.

Pag 37: Bibliografía.

INTRODUCCIÓN.

Durante el actual siglo XXI, la lista Forbes se ha asentado como uno de los criterios vitales a la hora de considerar a una empresa como exitosa.

Por esta razón hemos considerado su lista como base de datos para analizar a rasgos generales como se están comportando estas empresas en el ámbito de salud financiera y análisis fundamental.

Hemos tomado la lista de un año al azar (2004) de este siglo, ya que realmente la lista Forbes abarca empresas de todo el mundo y es muy variable en función de cada año.

Nuestra base de datos consta de 8 variables, en las cuales se mide el ranking en el que se encuentra la empresa, el nombre de la empresa, su nacionalidad, el sector económico al que pertenece, su número de ventas, beneficios, sus activos, y por último su valor de mercado, que en un principio se calcula mediante una estimación de la salud económica de cada empresa y sus márgenes de escalabilidad y beneficios.

Siguiendo la base de datos hemos comenzado analizando los beneficios(profits) de todas las empresas de la lista, sin importar la posición del ranking en la que se encontrasen, todas por igual. Después nos centraremos en el valor de mercado (market value) de cada una de ellas, para por último centrarnos en las variables nominales, como pueden ser la nacionalidad o los distintos sectores a los que pertenecen las empresas.

El objetivo de este trabajo es aprender a manejar y depurar una base de datos real suficientemente grande para poder realizar un análisis estadístico descriptivo sobre diversas variables. Así como razonar los resultados obtenidos y familiarizarnos con herramientas informáticas como pueden ser “excel” o “google colab”.

I. BENEFICIOS / PROFITS

Hemos realizado la siguiente tabla de intervalos con los valores de los beneficios en billones de dólares de las 2000 empresas, teniendo en cuenta que son de naturaleza continua.

Para ello, en primer lugar, debemos de determinar el número de clases(**k**), mediante la fórmula de “Sturges” ($n > 50$). Después debemos de calcular la **amplitud** del intervalo, que se calcula como el **rango** ($x_{\max} - x_{\min}$) dividido entre k (sturges). A partir de aquí, construimos los límites inferiores y superiores de cada intervalo. Por último, calculamos los niveles asociados a cada intervalo y construimos el resto de la tabla.


Esta se compone de la **marca de clase(xi)**, el punto medio del intervalo nos será vital para calcular las medidas que veremos más adelante. A su vez, de la columna de las **ni**, la frecuencia absoluta, que nos indica el número de datos que pertenecen a cada intervalo (con su respectiva **NI**, la frecuencia absoluta acumulada, para calcularla hemos utilizado una tabla dinámica para facilitarnos el trabajo). Por último, también se encuentra la columna del **fi**, la frecuencia relativa, que se define como la división entre la frecuencia absoluta y el conjunto de todos los datos (con su respectiva **FI**, frecuencia relativa acumulada).

Nºrango	lim_inf	lim_sup	xi	ni	fi	porcentaje	Ni	Fi
1	-25,83	-21,806548	-23,818274	2	0,001	0,1	2	0,001
2	-21,086548	-17,063096	-19,074822	1	0,0005	0,05	3	0,0015
3	-16,086	-12,062548	-14,074274	2	0,001	0,1	5	0,0025
4	-12,0625	-8,0390477	-10,050774	2	0,001	0,1	7	0,0035
5	-8,03904	-4,0155877	-6,0273139	8	0,004	0,4	15	0,0075
6	-4,0155	0	-2,00775	265	0,1325	13,25	280	0,14
7	0	4,02345225	2,01172613	1673	0,8365	83,65	1953	0,9765
8	4,02345	8,04690225	6,03517613	36	0,018	1,8	1989	0,9945
9	8,04690225	12,0703545	10,0586284	8	0,004	0,4	1997	0,9985
10	12,0703545	16,0938068	14,0820806	1	0,0005	0,05	1998	0,999
11	16,0938068	20,117259	18,1055329	1	0,0005	0,05	1999	0,9995
12	20,117259	24,1407113	22,1289851	1	0,0005	0,05	2000	1
total				2000	1	100		


La tabla consta de 12 intervalos con una amplitud de 4 aproximadamente (4,02345225), partiendo desde el límite inferior, es decir, desde la empresa que menos profit tiene hasta la que más profit tiene.

-GRÁFICOS REPRESENTATIVOS:


-Diagrama de sectores:



-Gráfico de Barras:



-Gráfico de densidad (histograma más adelante):



Se puede apreciar con facilidad la **tendencia central de la variable**, con la cual las empresas tienden a tener profit de 0 billones de dólares. La inclinación es ligera hacia los valores negativos, como se muestra en el gráfico de densidad (línea de frecuencia), el diagrama de sectores (se aprecia claramente como el sector de color naranja es claramente superior al resto con un 83,65%, representando el profit de 0) y el de barras (apreciamos como a partir de la barra del centro, las barras negativas son ligeramente superiores a las del lado positivo, estabilizándose en los valores extremos de los mismos). Más adelante se observará claramente con el histograma.

Además, si observamos la columna del fi, se aprecia claramente como la mayoría de los valores de la variable se concentran en el centro (intervalo 7) y a medida que se alejan del centro, van disminuyendo progresivamente.

-MEDIDAS DE POSICIÓN:

Dentro de las medidas de posición podemos diferenciar las medidas de tendencia central que son aquellas que miden los valores medios de la serie y las medidas de tendencia no central que nos proporcionan información sobre la ubicación de los datos en un conjunto, sin verse afectadas por valores extremos.

Medidas de tendencia central:

Ya que hemos comenzado con las medidas de tendencia central, hemos realizado una tabla para poder observar mejor los datos.

Medidas de tendencia central	
Media aritmética	1,511218024
Media geométrica	#####
Media armónica	#####
Moda	[0 ; 4,02345225]
Mediana	0,001988063

La media geométrica, que estudia aquellos valores que tienen un efecto multiplicativo sobre el de los años anteriores en nuestro caso de estudio no nos sirve, ya que al integrar nuestra base de datos valores negativos, no podremos calcularla debido a que no tendría sentido calcular la raíz enésima de un número negativo.

La media armónica (inversa de las inversas), la cual mide variables con mismas longitudes pero en distintos tiempos tampoco puede aplicarse en nuestro caso de estudio por el mismo motivo que la geométrica. Si integra valores negativos, puede ser que la suma recíproca del denominador (nos estamos refiriendo a la fórmula), nos pueda dar cero y no tendría sentido ya que no podemos dividir ningún número entre cero.

Por lo tanto, acorde a la propia definición de estos dos tipos de medias y a las circunstancias dadas en nuestra base de datos, podemos afirmar que la media más representativa en nuestro caso de estudio es la media aritmética.

La media aritmética (también conocida como “promedio”), que mide el promedio de beneficios de todas las empresas que aparecen en la lista Forbes se calcula como la marca de clase multiplicada por las ni y todo ello dividido entre n (conjunto de datos). El resultado que nos ha dado es de 1.5 billones de dólares aprox, por lo tanto, el beneficio en billones de dólares medio de las empresas que aparecen en la lista Forbes del año 2004 es de 1.5. Esta media puede verse afectada por datos anómalos, más adelante lo analizaremos y realizaremos el cálculo de la media recortada.

La moda, que se define como el valor que más veces se repite en la distribución se encuentra en el intervalo número 7, el cual tiene una marcha de 2,01172613, con un total de 1673 empresas cuyo profit se encuentra en este rango. El cálculo de esta nos es muy útil ya que nos confirma la tendencia de la variable. Si observamos la tabla, apreciamos que el valor que más se repite se encuentra en el centro de la distribución, ratificándonos así la tendencia central de la variable y el correcto cálculo de la moda.

La mediana es la medida de tendencia central mide el valor que deja la mitad de los datos a la izquierda y la otra mitad a la derecha. Es lineal y robusta frente a valores atípicos, lo comprobaremos más tarde. Nos deja el mismo número de datos a la izquierda y a la derecha, esta se ha definido en 0,001988063.

Medidas de tendencia no central:

Ahora analizaremos las medidas de tendencia no central, hemos realizado una tabla para poder observar mejor los datos

Medidas de tendencia no central	
Q1	-13,0683989
Q2(mediana)	0,001988063
Q3	13,07621757
Percentil 0,3	-10,4531239
Percentil 0,7	10,4609736
Percentil 0,9	20,92194946

Hemos calculado diversas medidas de tendencia no central como por ejemplo los **cuartiles** 1 y 3 que posteriormente nos ayudarán a calcular el rango intercuartílico y luego, además, algún **percentil** para observar cómo se va distribuyendo la variable estudiada.

Por ejemplo, los percentiles de esta tabla indican que, si la empresa tiene 20.92 billones de dólares o más de beneficios, estaríamos hablando que esa empresa tiene más beneficios que el

90 por ciento de las empresas de la tabla, igual con el caso de los cuantiles, que dividen el 100 % de la tabla en tantas partes como cuantiles se indiquen. En este caso como hemos dividido en 3 cuantiles, cada cuantil representaría un 25 % del total de la lista.

-MEDIDAS DE DISPERSIÓN:

A continuación, hemos calculado las medidas de dispersión más características. Iremos comentándolas e interpretándolas según el orden que aparece en la siguiente tabla.

Medidas de dispersión	
Rango	46,79
Varianza	3,763517284
Desviación Típica	1,939978681
Coefficiente de variación	1,283718597
IQR	26,14461644
Media	1,511218024
MAD	2,207962968
Entropía Shannon	0,8216932

En cuanto a **la varianza**, la cual hemos calculado mediante el sumatorio de x_i al cuadrado multiplicado por la f_i y a todo ello le restamos la media al cuadrado es de 3,76 aprox. La varianza se define como la distancia media de las observaciones al centro y se interpreta según el contexto de la distribución y el tipo de la variable.

En nuestro caso de estudio, al estudiar el beneficio, afirmamos que es una varianza moderada, más bien pequeña ya que si la media se encuentra en 1.5, esta varía 3,76 por encima o por debajo de la media, lo cual es bastante óptima. Es decir, en media el beneficio de las empresas se encuentra -2.26 y 5.26, hay empresas que tienen unas pérdidas de 2.26 billones y empresas que tienen unas ganancias de 5.26 billones. No es una diferencia muy significativa teniendo en cuenta que en nuestra base de datos hay empresas que pierden 25 billones y otras que ganan 20 billones. Por lo tanto, nos encontramos ante una variable poco dispersa.

La desviación típica se halla haciendo la raíz cuadrada de la varianza, en este caso es de 1,9 aprox, nos ratifica la poca dispersión y la interpretación realizada en la varianza. Tiene la misma interpretación que la varianza, pero surgió como solución para obtener una medida de dispersión positiva sin ser excesivamente grande (si elevamos al cuadrado).

Nos ofrece información de la separación de los datos respecto a la media y nos será muy útil para calcular el coeficiente de variación.

MAD
$\text{abs}(xi - \text{media}) * ni$
50,6589838
19,07482187
28,14854775
20,10154775
48,21851099
532,05375
3365,617808
217,2663405
80,46902702
14,08208063
18,10553288
22,12898513
4415,925937
2,207962968

En cuanto la medida **MAD**, es una medida que resuelve el problema de los valores negativos simplemente utilizando el valor absoluto (antes no se concebía, no se puede derivar en valor absoluto) y elimina la necesidad de una desviación típica, suele ser más robusta que la varianza y tiene menos margen de error (ya que no eleva al cuadrado). Por ello, en nuestro caso es de 2,20, ligeramente menor que la varianza.

El coeficiente de variación (CV) o índice de variación de Pearson es otra medida que nos mide la dispersión (mide la distancia que tienen que recorrer los valores al centro) y se calcula cómo el cociente de la desviación típica entre la media. Hay que tener cuidado porque como bien indica la fórmula, depende mucho de como sean estos valores, sobre todo de la media. Si la media es cero o muy próxima a la desviación típica (lo que nos está sucediendo, 1,5 – 1,9), este pierde el significado y da valores muy grandes (normalmente suele ser menor que uno) y no tiene por qué implicar una gran

dispersión.

Al ser nuestro CV de 1,2, no nos fiaremos de él por lo que acabamos de comentar, no nos servirá para analizar la dispersión.

El **IQR** (Q3-Q1) es un índice de asimetría que mide la distancia entre cuartiles, a mayor sea el IQR mayor es la asimetría, en este caso no se encuentra cerca de 1 (es de 26,14) ya que estamos ante una gráfica más o menos simétrica, la mejor forma de observarlo es en la línea de frecuencias. Nos servirá más adelante para el análisis de datos anómalos.

La Entropía de Shannon mide la cantidad promedio de incertidumbre asociada con una variable y tiene muchas aplicaciones. Una entropía baja indica mayor predictibilidad, mientras que una entropía alta indica una mayor incertidumbre.

En nuestro caso es de 0,8216932, consideramos que es alta (rango 0-1), por lo tanto, la variable estudiada tiene mucha incertidumbre y es difícil de predecir.


	fi	$\log_2(fi)$	$fi * \log_2(fi)$
entropía de shanon	0,001	-9,96578428466209	-0,0099658
	0,0005	-10,9657842846621	-0,0054829
	0,001	-9,96578428466209	-0,0099658
	0,001	-9,96578428466209	-0,0099658
	0,004	-7,96578428466209	-0,0318631
	0,1325	-2,91593573521153	-0,3863615
	0,8365	-0,257562554623734	-0,2154511
	0,018	-5,79585928321978	-0,1043255
	0,004	-7,96578428466209	-0,0318631
	0,0005	-10,9657842846621	-0,0054829
	0,0005	-10,9657842846621	-0,0054829
	0,0005	-10,9657842846621	-0,0054829
total:	1	0	-0,8216932
Entropía = - sumatorio de $fi * \log_2(fi)$ = 0,8216932			

-MEDIDAS DE FORMA:

En lo que respecta a las medidas de forma hemos calculado el coeficiente de asimetría de Fisher y el coeficiente de Curtosis.


Coeficiente de asimetría de Fisher:

Este coeficiente mide el grado de simetría de la distribución. Simplemente lo hemos calculado con una función ya establecida en Excel (“coeficiente.asimetría”)y el resultado que nos ha salido es **-0,069093634**. Ante este resultado negativo, cómo ya veníamos prediciendo desde el principio, podemos afirmar que nos encontramos ante una distribución asimétrica negativa. Existe mayor concentración de valores a la izquierda de la media que a su derecha. Al principio afirmábamos que había una tendencia central pero ligeramente pronunciada hacia los valores negativos(izquierda), con este índice, podemos ratificarlo. No obstante, se trata de una asimetría negativa muy ligera.



Índice de Curtosis de Fisher:

El coeficiente de Curtosis mide el grado de concentración que presentan los valores alrededor de la zona central de la distribución. Hemos calculado este coeficiente con una función de Excel ya establecida (“curtosis”). El resultado que nos ha salido es de **-1,11918896** el cual nos indica que nos encontramos ante una distribución platicúrtica. Esto significa que presenta un reducido grado de concentración alrededor de los valores centrales de las variables (cuidado, alrededor, no en el centro). Esto se puede observar claramente en la columna del fi o en la siguiente gráfica. Es la misma que la anterior pero cambiando los ejes(vea mejor).



-ANÁLISIS DE DATOS ANÓMALOS:


1,5IQR	39,21692466
UB	52,29314223
LB	-52,28532353

En lo que respecta al análisis de los datos anómalos hemos obtenido las siguientes conclusiones.

Primero debemos realizar el **upper bound**($Q3 + 1,5IQR$) y el **lower bound**($Q1 - 1,5IQR$), los cuales nos indican un límite de beneficios (en nuestro caso) a partir del cual se empiezan a considerar beneficios atípicos o extremos tanto por la parte inferior de la variable como por la superior. En este caso de estudio, tanto el LB como el UB son el mismo con el signo cambiado, lo mismo ocurriría con el Q1 y el Q3, esto no significa que siempre tengan que ser iguales.

Por lo tanto, no existen datos anómalos en nuestra variable beneficios ya que el beneficio más bajo de -26 billones(pérdidas) y el beneficio más alto se encuentra en 20 billones, es decir, todos los valores de la variable se encuentran dentro del LB y el UB, descartando así la existencia de beneficios anómalos.

El gráfico que más representa la aparición de estos datos anómalos es el gráfico **Box-Plot** o el gráfico de **Caja y Bigotes**.




(gráfico seleccionando la fi)

El box-plot nos muestra que la mayoría de los intervalos tienen 1 o 2 empresas excepto los intervalos 6 y 7 que tienen 260 y 1600 empresas (aproximadamente) respectivamente, por lo que no podríamos hablar de datos anómalos como tal.

Nótese que cuando salimos de los intervalos centrales (5,6,7,8,9) es más difícil encontrar empresas, ya que estaríamos hablando de empresas con un profit mayor a 12 y menor a -8 (aproximadamente), que son profits que podríamos llamar extremos.

Tratando esta visión podríamos reiterar la tendencia central de la variable, ya que si sumamos la frecuencia de los intervalos 6 y 7 (desde -4 a 4), nos encontramos con más del 96 % de las empresas de nuestra lista Forbes 2000.



(gráfico seleccionando la xi, marca)

En este gráfico, se puede observar como todos los datos de nuestra variable se encuentran entre el UB y el LB

En definitiva, no hace falta por lo tanto realizar ninguna depuración de los datos, todos los datos que se encuentran en la variable los consideraremos útiles y reveladores para nuestro análisis.

-ÍNDICE de GINNI:

Finalmente, calculamos el Índice de Gini, el cual nos muestra la desigualdad existente entre los datos de la variable estudiada.

lim_inf	lim_sup	xi	ni	Ni	Fi	xi*ni	xi*ni(acum)	Qi	Fi-Qi
-25,83	-21,8065477	-23,8182739	2	2	0,001	-47,6365477	-47,6365477	-0,01576098	0,01676098
-21,086548	-17,0630957	-19,0748219	1	3	0,0015	-19,0748219	-66,7113696	-0,02207205	0,02357205
-16,086	-12,0625477	-14,0742739	2	5	0,0025	-28,1485477	-94,8599174	-0,03138525	0,03388525
-12,0625	-8,03904775	-10,0507739	2	7	0,0035	-20,1015477	-114,961465	-0,03803603	0,04153603
-8,03904	-4,01558775	-6,02731387	8	15	0,0075	-48,218511	-163,179976	-0,05398955	0,06148955
-4,0155	0	-2,00775	265	280	0,14	-532,05375	-695,233726	-0,2300243	0,3700243
0	4,02345225	2,01172613	1673	1953	0,9765	3365,61781	2670,38408	0,88352046	0,09297954
4,02345	8,04690225	6,03517613	36	1989	0,9945	217,266341	2887,65042	0,95540497	0,03909503
8,04690225	12,0703545	10,0586284	8	1997	0,9985	80,469027	2968,11945	0,98202887	0,01647113
12,0703545	16,0938068	14,0820806	1	1998	0,999	14,0820806	2982,20153	0,98668805	0,01231195
16,0938068	20,117259	18,1055329	1	1999	0,9995	18,1055329	3000,30706	0,99267843	0,00682157
20,117259	24,1407113	22,1289851	1	2000	1	22,1289851	3022,43605	1	0

Para calcular dicho índice emplearemos la siguiente fórmula: $IG = \frac{\sum (Fi - Qi)}{\sum Fi}$, tomando estos datos de la tabla y obteniendo los siguientes resultados:

Num_IG	0,71494739
Den_IG	5,124

Siendo por lo tanto nuestro índice de Gini: $IG = 0,139529155$. Este resultado puede expresarse también en % (multiplicándolo por 100): **13,95%**.

Como vemos, el índice de Gini toma un valor bajo, el cual muestra que existe una desigualdad del 13,95%.

APLICACIÓN A GOOGLE COLAB (PYTHON)

Cuando realizamos un análisis descriptivo de una variable con una gran cantidad de datos, cómo es este caso, pues tendemos a agrupar la variable en intervalos para poder trabajar de una manera más sencilla y simplificada. Además al tratarse la variable beneficios de una variable continua, también es conveniente realizar esta separación.

No obstante, cuando agrupamos por intervalos estamos perdiendo información. Es por ello que utilizaremos la herramienta google colab (python) con el fin de comprobar como varían las medidas que hemos calculado previamente calculandolas sin agrupar los datos de la variable.

-Importamos y mostramos nuestra base de datos:

```
# Instalar las bibliotecas necesarias si no están instaladas

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
from scipy.stats import pearsonr
from sklearn.datasets import load_iris

from google.colab import files

files.upload() #vamos a importar nuestra base de datos seleccionada

#Así mostrará nuestra base de datos
datos = pd.read_excel('forbes.xlsx')
display(datos)
```

rownames	rank	name	country	category	sales	profits	assets	marketvalue	
0	1	Citigroup	United States	Banking	94.71	17.85	1264.03	255.30	
1	2	General Electric	United States	Conglomerates	134.19	15.59	626.93	328.54	
2	3	American Intl Group	United States	Insurance	76.66	6.46	647.66	194.87	
3	4	ExxonMobil	United States	Oil & gas operations	222.88	20.96	166.99	277.02	
4	5	BP	United Kingdom	Oil & gas operations	232.57	10.27	177.57	173.54	
...	...	...	...	...	...	...	...	...	
1995	1996	1996	Siam City Bank	Thailand	Banking	0.48	0.02	11.27	1.47
1996	1997	1997	Yokogawa Electric	Japan	Business services & supplies	2.78	-0.22	2.96	3.29
1997	1998	1998	Hindalco Industries	India	Materials	1.35	0.14	2.47	2.76
1998	1999	1999	Nexans	France	Capital goods	5.09	0.00	2.71	0.88
1999	2000	2000	Oriental Bank of Commerce	India	Banking	0.81	0.10	7.16	1.17

2000 rows x 9 columns

-Le pediremos que nos realice un análisis descriptivo completo:

```
#Análisis descriptivo
 analisis_desc = datos.describe()
 print(analisis_desc)
```

```
count    2000.000000
mean      0.380180
std       1.763347
min      -25.830000
25%       0.080000
50%       0.200000
75%       0.440000
max       20.960000
```

Apreciamos como la media sigue siendo positiva, pero tiende mucho más a cero. Al agrupar la variable, la media incrementa ya que estamos teniendo mucho menos en cuenta toda esa gran cantidad de empresas con un beneficio que ronda los 0 billones de dólares(se simplifican).

En cuanto a la dispersión, se mantiene estable en ambos casos, siendo de 1.76 la DT sin agrupar y 1,9 agrupando.

La diferencia más significativa se aprecia en los cuartiles, siendo los calculados sin agrupar mucho menores que los calculados agrupando. Esto alterará el IQR y también la presencia de datos anómalos. Cabe mencionar, que, aunque la mayoría de las empresas tengan un beneficio de 0 billones, no podemos dejar de lado las empresas que tengan beneficios mayores o menores.

Realizaremos un gráfico Box-Plot para verlo con claridad:


```

▶ ## Crear un box plot con Seaborn
sns.set(style="whitegrid") # Establecer el estilo del fondo

plt.figure(figsize=(10, 6)) # Ajustar el tamaño del gráfico si es necesario

# Utilizar boxplot de Seaborn
sns.boxplot(y='profits', data=datos, palette='viridis')


```



Si analizamos la variable sin agrupar, al estar la mayoría en beneficio cero, nos sale que la mayoría del resto de datos de la variable los considera anómalos. Si solo analizáramos los datos que están en torno al beneficio cero, el estudio carecería de lógica. Aunque los que tengan muchos beneficios tengan valores altos, no por ello son anómalos, son también representativos y reveladores en nuestro estudio. De aquí radica la necesidad de agrupar e interpretar.

Por último, le pediremos que nos genere un histograma:

```
#HISTOGRAMA  
sns.set(style="whitegrid") # Cambiar el estilo  
sns.histplot(datos['profits'], kde=True, bins=20);
```



No varía casi nada en comparación con los datos de la variable agrupada. La línea de frecuencia es muy similar y representa también con claridad las empresas con beneficio cero, así como la clara tendencia central de la variable y su breve inclinación a la izquierda.

II. MARKET VALUE.

La primera variable continua (profits) tenía algunos valores negativos, ya que muchas grandes empresas se endeudan para invertir más dinero y sacar rentabilidad a un dinero que realmente no es suyo.

El ir pagando ese endeudamiento hace que acaben el año con profit negativo, pero no les importa porque creen que a largo plazo les será rentable.

En el caso de la segunda variable continua (market value) no habrá dígitos negativos, ya que el market value significa el valor de una empresa, el dinero que tendrías que pagar para comprarla, por así decirlo.

El market value es el dinero en el que está valorada la empresa, para valorar una empresa los expertos se basan en diversos parámetros tales como:

Las perspectivas del sector de dicha empresa a futuro, el nivel de endeudamiento que tenga esa empresa, el margen de mejora en los márgenes de beneficio, la imagen de marca y marketing, la fidelidad de los clientes a la empresa, etc...

En el caso de esta variable, su naturaleza es la de ir creciendo a lo largo de los años de la lista Forbes, ya que el sistema capitalista hace que en muchos casos las empresas más grandes son las que más crecen, además la inflación y el crecimiento de la economía hacen que, inevitablemente, el valor de las empresas crezca.

Éste fenómeno lo contemplaremos después, cuando con las medidas de forma o el índice de Ginni se aprecie que a mayor market value , menos empresas hay , ocurriendo de forma prácticamente exponencial.


En esta variable hemos realizado una tabla de intervalos mediante el proceso clásico, que también seguíamos en la variable profits.

Nºint	lim inf	lim sup	xi (marca)	ni	fi	porcentaje	Ni	Fi
1	0,02	12,92	6,47	1600	0,8	80	1600	0,8
2	12,92	25,82	19,37	211	0,1055	10,55	1811	0,9055
3	25,82	38,72	32,27	67	0,0335	3,35	1878	0,939
4	38,72	51,62	45,17	38	0,019	1,9	1916	0,958
5	51,62	64,52	58,07	24	0,012	1,2	1940	0,97
6	64,52	77,42	70,97	14	0,007	0,7	1954	0,977
7	77,42	90,32	83,87	14	0,007	0,7	1968	0,984
8	90,32	103,22	96,77	4	0,002	0,2	1972	0,986
9	103,22	116,12	109,67	5	0,0025	0,25	1977	0,9885
10	116,12	129,02	122,57	5	0,0025	0,25	1982	0,991
11	129,02	141,92	135,47	2	0,001	0,1	1984	0,992
12	141,92	154,82	148,37	0	0	0	1984	0,992
13	154,82	167,72	161,27	3	0,0015	0,15	1987	0,9935
14	167,72	180,62	174,17	4	0,002	0,2	1991	0,9955
15	180,62	193,52	187,07	0	0	0	1991	0,9955
16	193,52	206,42	199,97	2	0,001	0,1	1993	0,9965
17	206,42	219,32	212,87	0	0	0	1993	0,9965
18	219,32	232,22	225,77	0	0	0	1993	0,9965
19	232,22	245,12	238,67	1	0,0005	0,05	1994	0,997
20	245,12	258,02	251,57	2	0,001	0,1	1996	0,998
21	258,02	270,92	264,47	0	0	0	1996	0,998
22	270,92	283,82	277,37	1	0,0005	0,05	1997	0,9985
23	283,82	296,72	290,27	2	0,001	0,1	1999	0,9995
24	296,72	309,62	303,17	0	0	0	1999	0,9995
25	309,62	322,52	316,07	0	0	0	1999	0,9995
26	322,52	335,42	328,97	1	0,0005	0,05	2000	1
Total				2000	1		2000	

maximo	328,54
mínimo	0,02
rango	328,52
k	25,4749059
amplitud	12,8958278
n	2000


GRÁFICOS REPRESENTATIVOS:

-Diagrama de sectores:



-Gráfico de barras:



-Histograma de frecuencias:**-Línea de frecuencia:**

Nuestra línea de frecuencias nos muestra lo expresado anteriormente, podemos observar que la mayoría de las empresas tienen un valor de mercado que se sitúa en los primeros dos intervalos, desde [0,02-12,92] hasta [12,92-25,82], descendiendo de forma logarítmica inversa (log base 1/10). Por lo tanto, la tendencia de esta variable no es ni mucho menos parecida a la de la variable profits(central), esta no se sitúa para nada en el centro, concentrándose la mayoría de los datos hacia la izquierda.

Esto sucede porque habitualmente en el mundo empresarial, las empresas más grandes son las que más crecen, y a las más pequeñas les suele costar más dar el salto al siguiente escalón. Siendo así mucho más habitual ver grandes empresas con valores entre 0 a 25 billones que empresas con un valor de más de 100 billones.

MEDIDAS DE POSICIÓN:

Procederemos a calcular las medidas de posición más representativas en esta variable, descritas en la variable profits.

Medidas de tendencia central:

Medidas de tendencia central	
Media aritmética	13,6037
Media geométrica	#####
Media armónica	64,3256143
Moda	[0,02;12,92]
Mediana	167,72

La media geométrica, al realizar su fórmula, nos sale un número elevado demasiado grande que tiende a infinito, por lo tanto, no podemos calcularla. A su vez, esta variable mide valores de un solo año por lo que se contradice con la propia definición de la media geométrica (valor multiplicativo durante los años), lo cual nos indica que carece de sentido calcularla.

La media armónica en esta variable tiene el mismo problema que la geométrica (mide distancias en distintos tiempos), al analizar únicamente un año, carece de sentido calcularla. Esta calculada pero no la podemos dar una interpretación adecuada.

Por lo tanto, acorde a la propia definición de estos dos tipos de medias y a las circunstancias dadas en nuestra base de datos, podemos afirmar que la media más representativa en nuestro caso de estudio es la media aritmética.

La media aritmética nos sale de 13.6 aprox. Este resultado nos indica el valor de mercado medio de toda la lista Forbes del año 2004, es decir que, en media, las empresas tienen un valor de mercado de 13.6 billones de dólares aproximadamente.

La moda, se encuentra en el primer intervalo de la variable, la mayoría de las empresas de la lista tienen entre 0.02 y 12.92 billones de dólares de valor de mercado. Con un total de 1600 empresas que se encuentran en este tramo. Esta medida, nos ayuda a ratificar la tendencia que sigue la variable, previamente comentada.

La mediana se ha definido en 167,72, es el valor que deja tanto a la izquierda como a la derecha el mismo número de datos (cuartil Q2), se sitúa justo en medio de todos los datos de la variable.

Medidas de tendencia no central:

Procederemos a calcular los cuartiles y percentiles más significativos de la variable market value.

Medidas de tendencia no central	
Q1	80,645
Q2(mediana)	167,72
Q3	254,795
Percentil 0,3	98,06
Percentil 0,7	237,38
Percentil 0,9	307,04

En cuanto al cálculo de los cuartiles y percentiles, es interesante comentar que son la medida que más varía al agrupar la variable, nos descartará la presencia de datos anómalos. Nos indican que datos distribuyen o cortan la variable en distintos trozos por así decirlo.

La mediana se encuentra cerca de ser el doble del Q1 , los cuantiles y los percentiles guardan relación , ya que si calculásemos por ejemplo el percentil 50 , debería encontrarse cerca de la mediana, cómo así ocurre en los cuartiles calculados.

-MEDIDAS DE DISPERSIÓN:

Estas son las medidas de dispersión más significativas acorde a la variable.

Medidas de dispersión	
Rango	328,5
Varianza	750,06558
Desviación Típica	27,3873252
Coefficiente de variación	2,01322619
IQR	174,15
Media	13,6037
MAD	9,17484979
Entropía Shannon	1,19888916

En cuanto a **la varianza**, nos sale muy elevada por hecho de que se tiene que elevar al cuadrado, es por ello por lo que utilizaremos la desviación típica para interpretar la dispersión.

La desviación típica nos sale de 27.38 aprox. Como bien sabemos es la distancia media de los valores al centro. ¿Es mucho o es poco? Es complicado de interpretar, pero según nuestro criterio la consideramos bastante alta. Si la media se sitúa en 13 y hacia arriba o hacia abajo varía en 27, es una diferencia bastante significativa teniendo en cuenta que estamos hablando de billones de dólares. Puede haber empresas con valor de mercado 0 (no puede ser negativo) y otras con valor de mercado de 40 billones aprox, la diferencia es muy grande y significativa, lo que nos hace concluir que nos encontramos ante una variable muy dispersa.

Lo comprobaremos con el coeficiente de variación.

MAD
$\text{abs}(xi - \text{media}) * ni$
2070,4
3655,884115
2089,659985
1683,84726
1376,95584
986,62494
1165,96074
386,30584
546,979125
611,317875
270,66906
0
483,084285
695,28664
0
399,54006
0
0
238,550665
502,63686
0
277,231315
579,95946
0
0
328,805515
18349,69958
9,17484979

En cuanto la medida **MAD**, en esta variable nos es muy representativa, ya que varía mucho en cuanto de la desviación típica (no ocurría en la variable profits). Se sitúa en 9, siendo la DT de 27, es normal que sea menor, ya que no tiene el margen de error de tener que realizar la corrección de la elevación al cuadrado. Por lo tanto, para interpretar la dispersión, nos serviría mucho más la MAD que la DT. Aún así una MAD de 9 en esta variable no es baja, pero se aleja mucho del 27 de la DT.

El coeficiente de variación (CV) o índice de variación de Pearson es muy útil para medir esta distancia entre la media y los valores. Nos sale de 2 aprox. Es raro, ya que tiende a ser menor que uno. Nos está indicando entonces una dispersión muy elevada, como hemos comentado previamente.

Si hacemos el CV con la MAD nos sale de 0.6 aprox, es un cambio muy drástico frente al CV calculado con la DT que era de 2 aprox. Por lo tanto, es importante conocer también la medida MAD, ya que esta es mucho más efectiva y se aproxima más al resultado real, no tiene tantos errores como la DT.

El **IQR** (Q3-Q1), al agrupar la tabla no es muy representativo, pero podemos comentar que es relativamente pequeño, ya que muchos de los valores están concentrados en la parte baja de la tabla.

fi	log2(fi)	fi*log2(fi)
0,8	-0,321928094887362	-0,257542476
0,1055	-3,2446850959549	-0,342314278
0,0335	-4,89969509420431	-0,164139786
0,019	-5,7178567712185	-0,108639279
0,012	-6,38082178394093	-0,076569861
0,007	-7,15842936260448	-0,050109006
0,007	-7,15842936260448	-0,050109006
0,002	-8,96578428466209	-0,017931569
0,0025	-8,64385618977473	-0,02160964
0,0025	-8,64385618977473	-0,02160964
0,001	-9,96578428466209	-0,009965784
0	0	0
0,0015	-9,38082178394093	-0,014071233
0,002	-8,96578428466209	-0,017931569
0	0	0
0,001	-9,96578428466209	-0,009965784
0	0	0
0	0	0
0,0005	-10,9657842846621	-0,005482892
0,001	-9,96578428466209	-0,009965784
0	0	0
0,0005	-10,9657842846621	-0,005482892
0,001	-9,96578428466209	-0,009965784
0	0	0
0	0	0
0,0005	-10,9657842846621	-0,005482892
Total	1	-152,2424383
entropia de shanon = - sumatorio (fi*log2(fi)) = 1,198889155		

La Entropía de Shannon en este caso, nos da un resultado un tanto raro, ya que es ligeramente superior a uno, el cual nos puede indicar la baja predictibilidad de la variable y la gran incertidumbre que posee.


-MEDIDAS DE FORMA:

Calcularemos el coeficiente de asimetría de Fisher y el índice de curtosis de Fisher, como hicimos en la anterior variable.

Coefficiente de asimetría de Fisher:

Este coeficiente como bien sabemos mide la simetría de la distribución. Como hemos comentado antes en la tendencia, debería salirnos negativo ya que hay muchos más valores a la izquierda que a la derecha de la distribución. Efectivamente nos sale de **-2,30926**, indicando que nos encontramos ante una distribución asimétrica negativa. Nos sale muy alejado de 0, esto es porque la mayoría de los datos se encuentran muy lejos de la mediana, al contrario que en profits que nos encontrábamos con una línea de frecuencias que era bastante simétrica y parecida a ambos lados de la mediana.

Se observa perfectamente en la línea de frecuencias.



Índice de Curtosis de Fisher:

Cómo ya sabemos, este índice mide el grado de concentración que presentan los valores alrededor de la zona central de la distribución. Sabemos que, en esta variable, para nada se agrupan los valores cerca del centro por lo que nos tendrá que dar negativo (curva platicúrtica). El resultado obtenido es de **-1,2**, nos indica que hay un escaso grado de concentración de valores alrededor del centro de la variable.


No vamos a poner el gráfico, porque ni siquiera se puede observar, al haber tan pocos valores cerca del centro.

-ANÁLISIS DE DATOS ANÓMALOS

1,5IQR	261,225
LB	-180,58
UB	516,02

En este caso hallamos los valores anómalos entre aquellos que sean mayores al UB ($Q3 + 1,5 \cdot IQR$) y aquellos que sean menores al LB ($Q1 - 1,5 \cdot IQR$), en esta variable no tenemos ningún dato anómalo. Todos nuestros valores se encuentran dentro de estos límites.

Si visualizamos el gráfico, observamos como la todos los datos se encuentran dentro de los bigotes o los límites LB y UB.



-ÍNDICE DE GINI.

Indice de gini						
xi	ni	Fi	xi*ni	Xi*ni(acum)	Qi	Fi - Qi
6,47	1600	0,8	10352	10352	0,380484721	0,4195153
19,37	211	0,9055	4087,07	14439,07	0,530703779	0,3747962
32,27	67	0,939	2162,09	16601,16	0,610170762	0,3288292
45,17	38	0,958	1716,46	18317,62	0,673258746	0,2847413
58,07	24	0,97	1393,68	19711,3	0,724483045	0,245517
70,97	14	0,977	993,58	20704,88	0,761001786	0,2159982
83,87	14	0,984	1174,18	21879,06	0,804158427	0,1798416
96,77	4	0,986	387,08	22266,14	0,818385439	0,1676146
109,67	5	0,9885	548,35	22814,49	0,838539883	0,1499601
122,57	5	0,991	612,85	23427,34	0,861065004	0,129935
135,47	2	0,992	270,94	23698,28	0,871023325	0,1209767
148,37	0	0,992	0	23698,28	0,871023325	0,1209767
161,27	3	0,9935	483,81	24182,09	0,888805619	0,1046944
174,17	4	0,9955	696,68	24878,77	0,914411888	0,0810881
187,07	0	0,9955	0	24878,77	0,914411888	0,0810881
199,97	2	0,9965	399,94	25278,71	0,929111565	0,0673884
212,87	0	0,9965	0	25278,71	0,929111565	0,0673884
225,77	0	0,9965	0	25278,71	0,929111565	0,0673884
238,67	1	0,997	238,67	25517,38	0,937883811	0,0591162
251,57	2	0,998	503,14	26020,52	0,956376574	0,0416234
264,47	0	0,998	0	26020,52	0,956376574	0,0416234
277,37	1	0,9985	277,37	26297,89	0,966571227	0,0319288
290,27	2	0,9995	580,54	26878,43	0,987908804	0,0115912
303,17	0	0,9995	0	26878,43	0,987908804	0,0115912
316,07	0	0,9995	0	26878,43	0,987908804	0,0115912
328,97	1	1	328,97	27207,4	1	0
		24,447				3,4168031
IG	0,1397637					

Num_IG	3,4168031
Den_IG	24,447
IG	0,1397637

Calculando el Índice de Ginni podemos observar que el market value está poco distribuido entre los intervalos, y que hay varios intervalos que concentran la mayoría de las empresas ya que un buen reparto conllevaría que las fi fueran parecidas y el índice de ginni se acercara a 2.

El resultado en esta variable es muy parecido que al anterior, tomamndo un valor bajo también, el cual muestra que existe una desigualdad del 13,97%.

APLICACIÓN A GOOGLE COLAB (PYTHON)

Al igual que en la variable profits, vamos a comparar que resultados nos darían las medidas más significativas si no agrupamos la variable, para así poder comparar.

-Le pediremos que nos realice un análisis descriptivo completo:

```

                marketvalue
count    2000.000000
mean      11.877655
std       24.460197
min        0.020000
25%        2.720000
50%        5.150000
75%       10.602500
max       328.540000

```


Podemos apreciar como los valores son muy parecidos a los obtenidos en nuestro estudio.

En cuanto a la media, esta esta en torno a 11,8 y a nosotros nos ha salido de 13 aprox, lo cual es bastante parecido.

En relación con la dispersión, muy parecida también, sin agrupar es de 24 aprox y agrupando de 27, no varía casi nada.

La diferencia más significativa se aprecia en los cuartiles, siendo los calculados sin agrupar mucho menores que los calculados agrupando. Esto alterará el IQR y también la presencia de datos anómalos.

Realizaremos un gráfico Box-Plot:



Con este gráfico podemos comentar varias cosas.


En primer lugar, nos ratifica la moda de la variable, se observa claramente como la mayoría de los datos se encuentran entre 0 y 20 billones aprox de valor de mercado.

Por otro lado, al no agrupar nos aparecen unos cuantos valores anómalos, esto es lo que más varía si no agrupamos la variable.

No obstante, al igual que en la variable anterior estos datos son anómalos respecto de la media, pero según nuestro criterio y para nuestro caso de estudio no son extremos y no deberían eliminarse. De aquí radica la necesidad de la interpretación humana.

Por qué iban a ser anómalos, queremos analizar la lista Forbes en conjunto y es lógico que haya empresas que tengan un valor de mercado mucho mayor pero no por ello debemos eliminarlos. Todo esto dependerá del criterio de cada individuo y de cómo quiera enfocar el proyecto. En nuestra opinión, no consideramos estos datos súper extremos, de hecho, pueden ser muy reveladores ya que, si se analiza la correlación, se puede observar por qué unos tienen tanto y otros tan poco. Por lo tanto, no los podemos eliminar sin criterio alguno.

Por último, le pediremos que nos genere un histograma:



Este gráfico, se parece mucho a la línea de frecuencias observada con el excel y nos ratifica la moda que decíamos que tenía la variable, así como la tendencia y la distribución de los datos en conjunto.

III. SECTORES.

El principal objetivo de una empresa debería ser crear riqueza y lucrarse económicamente. Cada empresa puede encontrar la forma de lucrarse de distintas formas, dependiendo de la forma que se beneficie se le encasilla en un sector u otro, por ejemplo, los bancos están en el sector de los bancos o los supermercados o cadenas alimenticias están en el sector de alimentación.

A diferencia de las variables continuas, no tenemos la necesidad de agrupar la variable, no tiene sentido hacerlo ya que no tenemos que simplificar los datos. Crearemos una tabla de frecuencias para observar mejor los datos.

Sectores	ni	fi	Ni	Fi
Aerospace & defense	19	0,0095	19	0,0095
Banking	313	0,1565	332	0,166
Business services & supplies	70	0,035	402	0,201
Capital goods	53	0,0265	455	0,2275
Chemicals	50	0,025	505	0,2525
Conglomerates	31	0,0155	536	0,268
Construction	79	0,0395	615	0,3075
Consumer durables	74	0,037	689	0,3445
Diversified financials	158	0,079	847	0,4235
Drugs & biotechnology	45	0,0225	892	0,446
Food drink & tobacco	83	0,0415	975	0,4875
Food markets	33	0,0165	1008	0,504
Health care equipment & services	65	0,0325	1073	0,5365
Hotels restaurants & leisure	37	0,0185	1110	0,555
Household & personal products	44	0,022	1154	0,577
Insurance	112	0,056	1266	0,633
Materials	97	0,0485	1363	0,6815
Media	61	0,0305	1424	0,712
Oil & gas operations	90	0,045	1514	0,757
Retailing	88	0,044	1602	0,801
Semiconductors	26	0,013	1628	0,814
Software & services	31	0,0155	1659	0,8295
Technology hardware & equipment	59	0,0295	1718	0,859
Telecommunications services	67	0,0335	1785	0,8925
Trading companies	25	0,0125	1810	0,905
Transportation	80	0,04	1890	0,945
Utilities	110	0,055	2000	1
Total	2000	1	2000	1

Al tratarse de una variable nominal, no podemos hablar de tendencia ya que este tipo de variables representan categorías sin un orden intrínseco. Por ejemplo, en las variables anteriores, estas iban de mayor a menor o viceversa. En esta variable como las categorías tienen letras, las ordenamos alfabéticamente, lo que hace imposible hablar de una tendencia o forma, simplemente podemos comentar sobre que categorías/sectores son más representados en el mercado.

Podemos apreciar con diferencia que el sector que más empresas tiene en la lista Forbes es el sector bancario, simplemente creemos que es lógico ya que se lucran sacando rendimiento al dinero de los usuarios de a pie.


En un segundo escalón se sitúan empresas de sectores como Utilities que son básicamente empresas que dan un servicio público, Insurance, que son compañías de seguros, también empresas de finanzas diversificadas, empresas petrolíferas y de combustibles fósiles, empresas de materiales de construcción y de transportes y logística.

En el último escalón se encuentran sectores en los que es más difícil convertirse en empresas referente o que simplemente hace falta abarcar mucho capital para conseguir una buena empresa en ese sector, como pueden ser sectores de aerolíneas, conglomerados, compañías de intercambio al por menor, hostelería o semiconductores.

En los siguientes gráficos lo podemos observar claramente.

-GRÁFICOS REPRESENTATIVOS:

-Diagrama de sectores:



-Gráfico de Barras:



-Polígono de Frecuencias:

Realizando un polígono de frecuencias se puede apreciar la diversificación en sectores, viendo que la mayoría de ellos tienen entre el 2% y el 6% del total de la lista, siendo el porcentaje medio de 3,61 %. También se puede apreciar la superioridad del sector bancario representando casi un 16 % del total.

-MEDIDAS DE POSICIÓN:

Dentro de las medidas de posición previamente descritas, en la variable sectores podemos diferenciar las siguientes.

Medidas de tendencia central:

Medidas de tendencia central	
Media aritmética	74,07407407
Media geométrica	60,8789911
Media armónica	51,35594299
Moda	Banking(313)
Mediana	#####

La media geométrica, a pesar de que está calculada, no tiene sentido en esta base de datos ni en esta variable ya que cómo mide el efecto multiplicativo a lo largo de los años y nosotros estamos analizando la lista Forbes de un único año (2004), pues carece de sentido realizar una interpretación.

La media armónica (inversa de las inversas), la cual mide variables con mismas longitudes, pero en distintos tiempos tampoco puede aplicarse en nuestro caso de estudio por el mismo motivo que la geométrica, ya que mide longitudes en distintos tiempos y solo analizamos un año determinado, no podemos hacer entonces una interpretación.

Por lo tanto, acorde a la propia definición de estos dos tipos de medias y a las circunstancias dadas en nuestra base de datos, podemos afirmar que la media más representativa en nuestro caso de estudio es la media aritmética.

La media aritmética, con resultado de 74 aproximadamente, nos indica que la media de empresas en los sectores es de 74. Esta se puede ver muy afectada por la presencia de datos anómalos, lo comprobaremos más adelante con el cálculo de la media recortada.

La moda, se encuentra en el sector “Banking”, integrando 313 empresas dentro del sector, siendo el sector que más empresas integra con bastante diferencia.

La mediana, al igual que hemos comentado previamente con la tendencia no tiene sentido calcularla en una variable nominal. En esta variable nominal las categorías simplemente nombres de sectores que no tienen un significado numérico o un orden inherente y, por lo tanto, no se puede determinar que categoría se encuentra en el “medio”.

Medidas de tendencia no central:

Por el mismo motivo por el cual no hemos podido calcular la mediana (no deja de ser un cuartil), no hemos podido calcular las medidas de tendencia no central (cuartiles, percentiles...).

-MEDIDAS DE DISPERSIÓN:

Acorde a la dificultad de calcular medidas numéricas debido a el tipo de la variable, las medidas que hemos considerado más representativas son las siguientes.

No obstante, sectores es una variable muy diversificada como se puede observar si calculamos la varianza, la desviación, además con el paso de los años van surgiendo nuevos sectores.

Medidas de dispersión	
Rango	294
Varianza	3178,3649
Desviación Típica	56,376989
Coefficiente de variación	0,7610894
Media	74,074074

En cuanto a **la varianza**, debido a la elevación al cuadrado, nos sale muy grande, es por ello por lo que utilizaremos para interpretar la desviación típica.

La desviación típica se halla haciendo la raíz cuadrada de la varianza, para corregir el error de la elevación al cuadrado. Nos sale de 56 aprox. Según nuestro criterio, consideramos que es bastante alta. Si la media está en 74 empresas en cada sector y varía en 56 empresas tanto por encima como por debajo, nos parece una dispersión bastante notable. La distancia media de los valores al centro, teniendo en cuenta la media, es bastante significativa.

Nos apoyaremos en el coeficiente de variación para ratificar nuestra interpretación.

El coeficiente de variación (CV) o índice de variación de Pearson nos ha salido de 0,76, del 76%. Este valor, según el contexto de la variable es bastante alto. Por lo tanto, los datos son bastante dispersos, nos encontramos con una alta variabilidad y afirmamos que la variable estudiada (sectores) es considerablemente dispersa.

-MEDIDAS DE FORMA:


En cuanto a las medidas de forma, por el mismo motivo comentado previamente (se trata de variable nominal), no podremos hablar de forma, simplemente podremos decir que los datos están **ordenados alfabéticamente**.

-ANÁLISIS DE DATOS ANÓMALOS:

Al no tener sentido el cálculo de los cuartiles, nos preguntamos, ¿cómo podremos saber el upper bound y el lower bound?

Pues la única forma que se nos ocurrió fue extrayendo los datos anómalos a partir del gráfico de caja y bigotes o box-plot. A continuación, lo comentaremos.

Hemos realizado un box-plot para ver a rasgos generales como se sitúan los datos con respecto de la media, y hemos podido observar que el sector bancario es el que representa un valor anómalo ya que se aleja del error. Se puede observar claramente en el gráfico.




El Box-plot nos ha llevado a pensar que sería interesante ver como varían nuestras medidas de dispersión desestimando los datos anómalos, ya que sabemos que influyen bastante en la obtención de medidas como la media, la varianza, la DT o el coeficiente de variación.

	con anómalos	sin anómalos
m.aritmética	74,07407407	61,16
m.geométrica	60,8789911	54,88539389
moda	313	112
varianza	3178,364883	700,6944
DT	56,37698895	26,47063278
CV	0,761089351	0,432809562

Los resultados obtenidos con la depuración eran previsibles. Se ha producido una disminución de las medidas de dispersión de manera considerable. La media se ha reducido a en torno a 20 puntos y se queda en 55 aprox, la moda cambia drásticamente a el valor de 112 empresas, correspondiente a Insurance, la varianza se ha reducido en 2000 y pico aprox, la desviación típica en torno a 30 puntos aprox y por consiguiente el CV se ha reducido a menos del 50%, alcanzando así un valor más moderado. El valor de 310 empresas en el sector Banking y el de 112 empresas de diversas entidades financieras (estos son los dos valores eliminados) se diferenciaban tanto del resto de sectores que influía mucho en las medidas de dispersión, al eliminar estos datos, estas se reducen considerablemente pero aún así, la variable continúa siendo dispersa, aunque ciertamente bastante más moderada.

Si volvemos a realizar el gráfico Box-Plot después de nuestra depuración, se observa que la presencia de datos anómalos es nula.



-ÍNDICE DE GINNI:

Al ser una variable nominal no disponemos de x_i y por consiguiente es imposible realizar el índice de ginni.

APLICACIÓN A GOOGLE COLAB (PYTHON)

En esta variable, al no tener los valores agrupados, podemos directamente comprobar si las medidas realizadas en nuestro Excel son correctas, así como comprobar si el análisis de datos anómalos también está bien hecho.


Por último, le pediremos que nos genere un histograma, donde se observe de manera clara la distribución de los datos.

-Le pediremos que nos realice un análisis descriptivo completo:

	category
count	27.000000
mean	74.074074
std	57.450933
min	19.000000
25%	40.500000
50%	65.000000
75%	85.500000
max	313.000000

Hemos comprobado, que los resultados obtenidos en nuestro estudio coinciden con los obtenidos en Google Colab.


-Le pediremos el gráfico Box-Plot:



Los datos anómalos observados en este gráfico son el 112 y el 313, los mismos que hemos eliminado en nuestro análisis, los cuales son lo que se alejan significativamente de la media.

A continuación, con el histograma se observará también muy bien.

-Por último, le pediremos que nos genere el histograma:



En este histograma, se puede apreciar como el valor 158 y el 313 se alejan de la media claramente, estando en la parte descendente del gráfico de densidad. Por otro lado, la parte más elevada del gráfico de densidad pertenece a aquellos sectores que integran entre 1 y 50 empresas, cómo veníamos comentando previamente.

Hemos querido realizar un análisis breve y genérico sobre la variable nacionalidades, al parecernos una variable muy importante ya que es uno de los factores más importantes a tener en cuenta para aparecer en la lista Forbes.


IV. NACIONALIDADES.

En cuanto a las sedes de las empresas de nuestra lista, podemos destacar que hemos encontrado un total de 61 sedes/ países distintos para las empresas, aunque hemos de destacar que las empresas pueden tener sede en dos países, por ejemplo, pueden tener sede compartida entre Reino Unido y Sudáfrica.

Nacionalidad	ni	fi	Ni	Fi
Africa	2	0,001	2	0,001
Australia	37	0,0185	39	0,0195
Australia/ United Kingdo	2	0,001	41	0,0205
Austria	8	0,004	49	0,0245
Bahamas	1	0,0005	50	0,025
Belgium	9	0,0045	59	0,0295
Bermuda	20	0,01	79	0,0395
Brazil	15	0,0075	94	0,047
Canada	56	0,028	150	0,075
Cayman Islands	5	0,0025	155	0,0775
Chile	4	0,002	159	0,0795
China	25	0,0125	184	0,092
Czech Republic	2	0,001	186	0,093
Denmark	10	0,005	196	0,098
Finland	11	0,0055	207	0,1035
France	63	0,0315	270	0,135
France/ United Kingdom	1	0,0005	271	0,1355
Germany	65	0,0325	336	0,168
Greece	12	0,006	348	0,174
Hong Kong/China	20	0,01	368	0,184
Hungary	2	0,001	370	0,185
India	27	0,0135	397	0,1985
Indonesia	7	0,0035	404	0,202
Ireland	8	0,004	412	0,206
Islands	1	0,0005	413	0,2065
Israel	8	0,004	421	0,2105
Italy	41	0,0205	462	0,231
Japan	316	0,158	778	0,389
Jordan	1	0,0005	779	0,3895
Kong/China	4	0,002	783	0,3915
Korea	4	0,002	787	0,3935
Liberia	1	0,0005	788	0,394
Luxembourg	2	0,001	790	0,395
Malaysia	16	0,008	806	0,403
Mexico	17	0,0085	823	0,4115
Netherlands	28	0,014	851	0,4255
Netherlands/ United King	2	0,001	853	0,4265
New Zealand	1	0,0005	854	0,427
Norway	8	0,004	862	0,431
Pakistan	1	0,0005	863	0,4315
Panama/ United Kingdom	1	0,0005	864	0,432
Peru	1	0,0005	865	0,4325
Philippines	2	0,001	867	0,4335
Poland	1	0,0005	868	0,434
Portugal	7	0,0035	875	0,4375
Russia	12	0,006	887	0,4435
Singapore	16	0,008	903	0,4515
South Africa	15	0,0075	918	0,459
South Korea	45	0,0225	963	0,4815
Spain	29	0,0145	992	0,496
Sweden	26	0,013	1018	0,509
Switzerland	34	0,017	1052	0,526
Taiwan	35	0,0175	1087	0,5435
Thailand	9	0,0045	1096	0,548
Turkey	12	0,006	1108	0,554
United Kingdom	137	0,0685	1245	0,6225
United Kingdom/ Australi	1	0,0005	1246	0,623
United Kingdom/ Netherl	1	0,0005	1247	0,6235
United Kingdom/ South A	1	0,0005	1248	0,624
United States	751	0,3755	1999	0,9995
Venezuela	1	0,0005	2000	1
Suma Total	2000	1	2000	1

En nuestro caso las empresas que tienen sede compartida en dos países las hemos considerado como si tuvieran sede en un país aparte, es decir no las hemos sumado a ambos países.

La representación gráfica mediante un diagrama de sectores es muy visual, ya que se puede observar fácilmente la superioridad en cuanto a representación de empresas de Estados Unidos y Japón, asentadas en el primer escalón, Japón con más de 300 empresas y EE. UU. con más de 700. Seguidas de Reino Unido, el cual tiene más de 130 empresas.




En el tercer escalón se sitúan países como India o China, que curiosamente son dos de los países más poblados del mundo con más de 20 empresas cada una. Además, también en ese rango podemos encontrar a países más pequeños pero cuyos gobiernos apuestan fuertemente por políticas capitalistas que fortalecen a las empresas como Países Bajos, Australia, Suecia o España, además de otros como Taiwán.

En el último escalón se encuentran países que tienen menos de 10 empresas en el top 2000 de Forbes, lo cual representa la pobreza o inestabilidad económica de esos países, como son los casos de Perú, Polonia, Jordania, Bahamas...

-ANÁLISIS GENÉRICO Y DATOS ANÓMALOS:

En esta variable el box-plot nos indica que los países con más de 100 empresas son considerados como valores anómalos, los cuales hacen variar mucho las medidas de dispersión.



	con anómalos	sin anómalos
m.aritmética	32,78688525	13,72413793
geométrica	7,571854123	6,23964892
moda	751 EEUU	65 (germany)
varianza	10538,1677	256,0618312
DT	102,655578	16,00193211
CV	3,130995129	1,165969927

En la tabla que observa que la diferencia de las medidas es muy grande si extraemos los datos que nos indica el box-plot, (EE. UU., Turquía y Japón), aunque bajo nuestro punto de vista tienen mayor anomalía los países que solo tienen una empresa en la lista, que por ejemplo Turquía (137). Así quedaría extrayendo también los países que solo tienen 1 o 2 empresas en la lista.

	con anómalos	sin anómalos
m.aritmética	32,78688525	19,79487179
geométrica	7,571854123	13,93003737
moda	751 EEUU	65 (germany)
varianza	10538,1677	268,2143327
DT	102,655578	16,37725046
CV	3,130995129	0,827348145

CONCLUSIONES:


A lo largo de la elaboración del trabajo, hemos podido extraer diversas conclusiones tanto del estudio específico, así como las distintas formas de trabajar y manejar las variables, según convenga.

-Podemos extraer más información y trabajar de una manera más completa con las variables continuas que con las discretas (en nuestro caso nominales).

-La variable “profits” tiene una interpretación muy distinta de la variable “market value” en cuanto a simetría, dispersión, etc...

- Hay que conocer el estudio, las unidades, el contexto para poder interpretar correctamente las medidas obtenidas. De aquí radica la necesidad de interpretación humana, la cual por ahora los ordenadores no tienen.

-La utilización de Google Colab nos ha ayudado mucho a comparar, visualizar y entender correctamente cada variable del caso de estudio. Te puede proporcionar también el grado de impacto que tienen unas variables sobre otras, esto es algo fundamental en cualquier estudio. Adjuntaremos dos gráficos donde se puede observar claramente.



Cuando el profit es de 0, el market value tiende a 0 también. En las dos variables por separado la mayoría de los valores se concentraban en torno al 0, es por ello por lo que la línea de regresión sale de esta forma. Nos ayuda a comprobar que, si juntamos las dos variables estudiadas, tienen sentido de manera conjunta, la línea de regresión es más que lógica.

Aquí se representa una matriz de correlaciones con una escala de colores que nos indica el grado de impacto de cada variable sobre otra según el color que representen en la escala.

Cada empresa de la lista Forbes tiene diversas variables explicativas que al analizarlas en conjunto (correlación), explican por qué se encuentran dentro de las 2000 mejores empresas del mundo. Nuestro trabajo debe ser entender y analizar que datos hacen que las empresas puedan aparecer en esta lista tan famosa.

BIBLIOGRAFÍA:

-The Forbes 2000 Ranking of the World's Biggest Companies (Year 2004):

<https://vincentarelbundock.github.io/Rdatasets/datasets.html>

-Descriptivo general (códigos google colab):

<https://colab.research.google.com/drive/1FVtzZDMGtHvros7GqtBuTYn37zJ5Jec?usp=sharing>